Machine Translated by Google

DAGA:使用生成方法的数据增强低资源标记任务

丁博生 12刘琳琳 12立东冰2 Canasai Kruengkrai † 3
Thien Hai Nguyen2 Shafiq Joty1罗思2 Chunyan Miao1
1新加坡南洋理工大学
2DAMO学院,阿里巴巴集团3日本国立信息学研究所
{bosheng.ding, linlin.liu, l.bing, thienhai.nguyen, luo.si}@alibaba-inc.com
canasai@nii.ac.jp {srjoty, ascymiao}@ntu.edu.sg

抽象的

数据增强技术已经
广泛用于提高机器学习性能,因为它们增强了泛化能力
模型的能力。在这项工作中,生成
低资源的高质量合成数据
标记任务,我们提出了一种新的增强方法,并训练了语言模型
在线性标记的句子上。我们的
方法适用于监督和
半监督设置。对于被监督的
设置,我们进行广泛的实验
关于命名实体识别（NER）,部分
语音 (POS) 标记和端到端目标
基于情感分析（E2E-TBSA)的任务。
对于半监督设置,我们评估
我们在仅给定未标记数据和未标记数据加上知识库
的条件下处理 NER 任务的方法。结果

表明我们的方法可以始终优于基线,特别是当给定的

黄金训练数据较少。1

1 简介

大量的训练数据通常是必不可少的
神经模型性能,特别是对于大型网络。拥有更多的训练数据有助于减少
过拟合并提高模型的鲁棒性。然而,准备大量带注释的数据是
通常是昂贵的、劳动密集型的和耗时的。
数据增强(Simard et al., 1998)是一种有用的
合成数据生成技术,即
广泛用于计算机视觉（Fawzi et al., 2016;

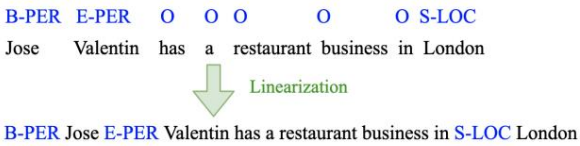

图 1:标记句子线性化的示例。
通过插入标签将所有单词及其标签配对
在单词之前（或之后）（删除了 O 标记）。

D Innocente 等人， 2017;王等人， 2019)和
演讲（Schluter 和 Grill ， 2015年； Ko 等人， 2017 年）。
但是由于语言的复杂性，
应用数据增强更具挑战性
自然语言处理（NLP)技术。
与计算机视觉和语音不同,在计算机视觉和语音中,手工制作的规则（如旋转、裁剪、遮罩、
等)可以很容易地应用于转换原始
数据,很难将这些规则概括为语言。虽然简单的失真通常会
不改变视觉信息的语义，
删除或替换单个单词可能会完全改变句子的含义。

一种成功的数据增强方法
NLP 中的反向翻译（Sennrich et al., 2016;
Fadaee 等人， 2017 年;董等人， 2017;于等人，2018）,其中使用翻译模型将单语句子从目标语言翻译成
源语言生成合成平行句。其他成功的方法包括:系统地重新排序一些节点的依赖项

在黄金数据中生成用于依赖解析的合成数据（Wang 和 Eisner， 2016 年）,利用
问题生成知识库（Serban
等人， 2016 年)并使用基于模拟的方法
为 QA 生成一组必备的玩具任务
（韦斯顿等人， 2015）。此外,同义词替换-

* 同等贡献。丁博生和刘琳琳是
阿里巴巴与南洋联合博士项目
科技大学。
† 在阿里巴巴集团达摩院完成的工作
1我们的代码可在https://ntunlpsg 获得。
github.io/project/daga/

2020 年自然语言处理经验方法会议论文集,第 6045-6057 页，
2020 年 11 月 16 日至 20 日。c 2020 年计算语言学协会

Machine Translated by Google

ment,随机删除/交换/插入,生成
使用 VAE 或预训练的语言模型
用于一些 NLP 任务（Kobayashi， 2018； Wei
和邹， 2019； Anaby-Tavor 等人， 2020;拉雷
等人， 2020； Kumar 等人， 2020 年）,但主要用于
翻译和分类任务。

与上述翻译和分类等下游任务相比,序列标记在面对数据增强
噪声时更加脆弱,因为

（令牌级)任务的更细粒度。使用弱标记器注释未标记
的数据,利用
对齐的双语语料库以诱导注释和
同义词替换是序列标记的三种尝试数据增强方法（Shang

等人， 2018； Yarowsky 等人， 2001 年;马修等人，
2019）。弱标记的数据将不可避免地引入更多的噪音。请注意,注
释未标记
带有弱标记器的数据需要域内数据
和领域内的知识,否则它可能会受到领域转移问题的影响（Bari
et al., 2020）。
利用对齐的双语语料库需要额外的资源,这些资源可
能不适用于
低资源语言。十的同义词替换依赖于额外的知识,例如 WordNet

(Miller, 1995),这是一个手动设计的字典,可能覆盖率低
（或不可用）
对于低资源语言。

在这项工作中,我们研究数据增强
使用序列标记的生成方法
任务。我们首先将标记的句子线性化为
图1 中的示例显示。然后在线性化数据上训练语言模型 (LM)

并用于生成合成标记数据。不像
使用弱标记器来标记看不见的数据,我们的
方法统一了句子生成的过程
并使用 LM 进行标记。具体来说,一句话和
它的一对标签（例如,“B-PER Jose”)被训练成
一起生成,其中标签词对
LM 在生成期间将很有可能选择（第 3.2 节）。我们的方
法不需要
WordNet 等其他资源。尽管如此,
如果未标记的数据或知识库可用,
我们的方法也可以灵活地利用这些资源
用一个简单但有效的条件生成
技术（§3.4）。

尽管最近的一些工作（Anaby-Tavor 等人,
2020； Raille 等人， 2020 年； Kumar 等人， 2020)也
利用 LM 进行数据增强,他们的方法
以句子级标签为条件来生成或修改训练数据,因此适用于

专门的分类任务。尽我们所能
知识,我们是第一个利用生成
用于生成细粒度合成的语言模型
用于序列标记任务的从头开始的数据,其中
引入了数据增强的新范式
在自然语言处理中。此外,我们的方法不依赖于
大型预训练模型,事实上,它采用了
简单的一层循环语言模型（Sun dermeyer et al., 2012）,更方
便
训练。我们的方法展示了令人鼓舞的
仅接受几千次训练时的性能
句子（§4）。

为了验证我们方法的有效性,我们
对不同的序列标记任务进行广泛的实验,包括命名实体识别(NER)、
词性 (POS) 和端到端基于目标的情感分析 (E2E-TBSA)。

我们的方法始终优于基线
监督和半监督方法
设置。与基线方法不同,我们的
方法从头开始生成新的合成数据,
因此引入了更多的多样性以减少过度拟合。对于半监督设
置,我们的方法
展示了从未标记的数据和知识库中利用有用信息的强大能力。

2 背景

命名实体识别 (NER) 命名实体是指作为人名的短语,

组织和地点等文字。例如,“[ORG UN] 官方 [PER Ekeus] 前往

[LOC 巴格达]”。命名实体识别是一种
信息抽取的重要任务和目标
将文本中的命名实体定位和分类到
预定义类型（Mikheev 等， 1999； Sang 和
德默德， 2003;李等人， 2020）。这是一项具有挑战性的
任务,原因有两个（Lample 等人， 2016 年）：
1) 在大多数语言和领域中,
NER 的手动标记训练数据是有限的;
2)很难从这个小样本中概括
由于种类的限制,训练数据的数量
可以是名字的单词。

词性 (POS) 标记词性
标记包括分配一个代表一个
给定句子中每个单词的语法类别。
它是大多数 NLP 系统和
是促进下游任务的基础,例如
作为句法分析(Schutze ¨ , 1993)和意见
分析（Liu 等人， 2015 年）。当前最先进的词性标注器
在 PTB-WSJ 上的准确率可以达到 97.80% 以上（Akbik
et al., 2018; Bohnet

Machine Translated by Google

等人， 2018 年） ,平均测试产量超过 96.50%
UD 中 21 种高资源语言的准确性
1.2 （海因策林和斯特鲁布， 2019）。然而,一个
当前 POS 标记器的问题之一是
在资源匮乏的语言和稀有词上,它们的准确性会显着降低（Plank 等人，
2016; Yasunaga 等人， 2018 年）。

基于目标的情感分析目标
基于情感分析的基本任务
情感分析,旨在检测句子中的观点目标并预测情感

目标上的极性（Liu et al., 2015; Chen
等人， 2017;李等人， 2018,2019a）。例如，
“USB3 外围设备明显便宜
比迅雷的那些”。在这句话中,两个
提到了意见目标,即“USB3 周边设备”和“ThunderBolt周边设备”以及用户
对第一个表达了积极的情绪,并且
对第二个负面情绪。李等人。
(2019a,b)提出 TBSA 的端到端解决方案（E2E TBSA） ,将
TBSA 转换为标记任务,旨在解决两个子任务（即

目标检测和情感分类)在一个
通过预测统一标签来统一人员配置。为了
例如,标签“B-POS”表示开头
具有积极情绪的目标。所以经过注释,上面的例子就变成了“[B-POS USB3]
[E-POS 外围设备] 明显便宜
比 [B-NEG ThunderBolt] [E-NEG 的]”。

3 建议方法

我们提出了一种新的数据增强方法
序列标记任务。我们首先线性化标记
句子,然后训练一个语言模型来学习
来自线性化序列的单词和标签的分布,用于生成合成训练

数据。条件生成技术也是
建议利用未标记的数据和知识
基地可用时。

3.1 标记句线性化

我们首先进行句子线性化来转换
将句子标记为线性序列,以便使用语言模型来学习分布

黄金数据中的单词和标签。如图1 所示,在相应的标签之前插入标签
线性化期间的单词,因此被视为这些单词的修饰符。对于频繁 O 的任务
标签,例如 NER 和 E2E-TBSA (Li et al., 2019a),
我们从线性化序列中删除这些标签。

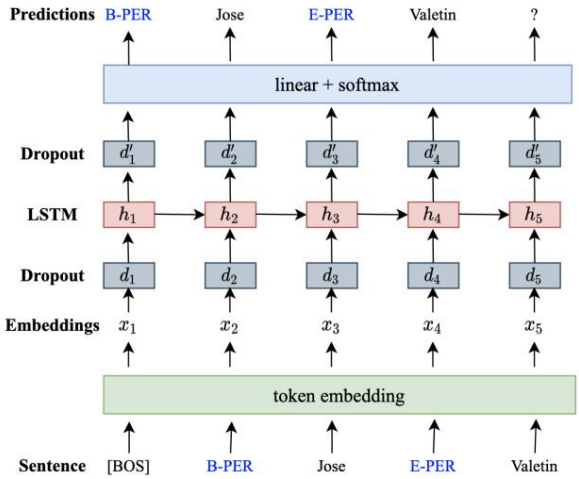

图 2:使用 LSTM 的语言模型架构。

同样,我们也可以在对应词之后插入标签。

在句子线性化之后,我们在词首添加了 special to kens
[BOS] 和 [EOS]
每个句子的结尾,分别。这些特别
令牌用于促进模型训练和数据
通过标记句子边界来生成。

3.2 语言建模和数据生成

将标记的句子线性化后,可以使用语言模型来学习单词的分布
和标签。更具体地说,我们使用一层
LSTM 循环神经网络语言模型
(RNNLM) 在我们的方法中,类似于
Sundermeyer 等人提出的模型。 （2012）。这
我们的 RNNLM 架构如图2 所示。

语言建模我们通过最大化下一个标记预测的概率来训练 RNNLM 。
给定一个句子,我们首先输入序列
标记（w1， w2， ... ， wN)到嵌入
层来查找相应的嵌入
(x1, x2, ... , xN),其中N是序列长度。
一个 dropout 层应用于每个 token embed ding xt
以生成dt = dropout(xt)。然后我们
将(d1, d2, ... , dN)输入 LSTM 以在每个位置产生隐藏状态ht = LSTM(dt , ht－1)
吨。另一个 dropout 层应用于隐藏状态
计算 d =辍学（HT）。
最后用一个linear+softmax层来预测
序列中的下一个标记。假设指数
词汇表中的记号wt是i , 我们有

Machine Translated by Google

[BOS] [labeled] B-PER Jose E-PER Valentin has a restaurant business in S-LOC London [EOS]

[BOS] [unlabeled] I have booked a flight to New York [EOS]

[BOS] [KB] We ate crepes in S-LOC Shibuya, saw cherry blossom bloom at Asakusa [EOS]

图 3:条件生成的示例。第一个序列来自黄金 NER 数据。第二个来自未标记的数据,因此没有标签。三是通过知识库匹配标注,浅草由于知识覆盖不完整,无法标注。

等式中的训练目标。 3:

$$s_{t-1} = MTd_{0\ t-1} \quad (1)$$

$$p_\theta(w_t \mid w_{<t}) = \frac{\exp(s_{t-1,i})}{\sum_{i=1}^{\tilde{n}} \exp(s_{t-1,i})} \quad (2)$$

$$p(w_1, w_2, \ldots, w_n) = \prod_{t=1}^{n} p_\theta(w_t \mid w_{<t}) \quad (3)$$

其中V是词汇的大小， $M \in R^{r \times V}$是一个可学习的权重矩阵，为其中r是LSTM 隐藏状态的维度， $s_{t-1,i}$是s_{t-1}的第 i 个元素。

生成在训练 RNNLM 之后,我们可以使用它来生成用于标记任务的合成训练数据。在生成过程中,仅将 [BOS] 令牌输入 RNNLM,并根据公式计算的概率对以下令牌进行采样。 2. 给定[BOS],一次自回归生成一个句子,其中上一步生成的token作为输入生成下一个。

如方程式所示。 2、RNNLM在生成过程中更容易在采样时挑选出概率高的token。由于抽样增加了随机性,RNNLM可以在给定相同上下文的情况下选择相似的替代方案。

假设我们在对应的词之前（在句子线性化期间)插入标签来训练 RNNLM,在给定“我已经预订航班”预测下一个标记时，“S LOC”的概率远高于其他选择,因为RNNLM 在训练数据中见过很多类似的例子,比如“a train to S-LOC”、“a trip to S-LOC”等等。然后我们根据“我已经预订了飞往 S-LOC 的航班”来预测以下单词。

在训练数据中,所有“S-LOC”后面都是位置词,所以“London”、“Paris”、“Tokyo”等都是可能的选择,它们的概率非常接近。由于增加了随机性,模型可以选择其中任何一个。当我们插入标签 af 时,以类似的方式预测标记ter 对应的词,除了词是在标签之前预测的。

3.3 后处理

生成的序列是线性化的mat格式,所以需要转换成和gold数据一样的mat格式。我们还引入了几个简单的规则来清理生成的数据:1)删除没有标签的句子； 2) 删除所有单词都是[unk]2 的句子； 3)删除标签前缀顺序不正确的句子（例如， NER数据中E-LOC在B-LOC之前）； 4)删除包含相同单词序列但不同标签的句子。

3.4 条件生成

我们提出了一种条件生成方法,以允许语言模型在某些低资源场景中可用时利用未标记的数据或知识库。考试用

例如,为 NER 注释大量电子商务产品标题可能会很昂贵,但获得产品属性和未标记数据的知识库（即字典)要容易得多。我们在每个序列的开头添加这些条件标签之一{[labeled],[unlabeled],[KB]}以标记它们的起源,其中 KB表示通过将知识边库与未标记数据进行匹配来标记序列。有关示例,请参见图3 。这允许语言模型在了解不同来源的同时学习这些序列之间的共享信息。在生成合成数据时,每个单词都以给定的条件标签 [labeled] 为条件,表示为c （条件类）。在我们将其输入语言模型后,接下来生成步骤中的所有 LSTM 隐藏状态h都包含c 的信息。此外， h还编码了所有其他先前标记的形成

2为了减少训练语言模型时的词汇量,将训练数据中只出现一次的单词替换为未知标记[unk]。

Machine Translated by Google

序列。当预测以 ht－1 为条件的下一个标记时,方程中的概率 pθ(wt |w<t) 。 2变为pθ(wt |w<t, c)。[3] CTRL (Keskar et al., 2019)中使用了类似的方法来控制文本生成期间的样式、特定于任务的行为等。

4个实验

在本节中,我们将介绍我们在监督和半监督设置中的实验。在监督设置中,只有黄金数据用于增强。在半监督设置中,我们还利用未标记的数据和知识库。

4.1 基本模型

语言模型我们使用第3.2节中描述的语言模型来生成合成数据。我们修改了 LSTM-LM 的解码器

Kruengkrai (2019)中的模型来实现这个语言模型。我们将 LSTM 隐藏状态大小设置为 512,嵌入大小设置为 300。我们对两个 dropout 层使用 dropout rate 0.5。所有语言模型都使用随机梯度下降 (SGD) 进行训练,初始学习率为 1,批量大小为 32。

如果开发集上的困惑度没有改善,学习率将在下一个 epoch 衰减 0.5 。
我们将最大 epoch 数设置为 30,如果开发集的困惑度在连续 3 个 epoch 中没有改善,我们会提前停止训练。在合成数据生成过程中,我们使用训练集中黄金句子的平均长度作为我们的最大句子长度。

序列标记模型我们使用 Flair 框架(Akbik et al., 2019)实施 BiLSTM-CRF 模型(Lample et al., 2016)来评估我们在 NER 和 POS 任务上的数据增强方法。4我们使用单层隐藏状态大小为 512 的 BiLSTM。在 BiLSTM 层之前和之后应用 Dropout 层,dropout 率为 0.5。所有序列标记模型都使用 Adam (Kingma and Ba, 2014)进行训练,初始学习率为 1e-3,批量大小为 32。如果开发集的性能在 3 个连续 epoch 中没有提高,学习率会衰减 0.5 。当学习率低于 1e-5或 epoch 数达到 100时,我们停止训练。我们使用 pre

为所有语言训练了 300 维 fastText 词嵌入（Bojanowski 等人， 2017 年） 。

我们采用相对简单的基本模型是因为:1)它们有助于避免在低资源设置下由于数据量小而可能出现的过拟合问题； 2)它们可以更忠实地理解所提出的数据增强方法的效果。

4.2 监督实验

为了验证我们的数据增强方法在监督设置中的有效性,我们在三种不同的标记任务上对其进行评估,包括 NER、POS和 E2E-TBSA。之前的大部分工作都依赖于附加信息,因此我们使用随机删除(rd) (Wei and Zou, 2019)作为我们的基线,其中随机删除了训练数据中 5% 的单词 5和相应的标签。有关我们监督实验中使用的方法的符号,请参见表1 。

方法说明	
金子	仅使用黄金数据。
创	我们的方法。使用语言模型生成合成数据,并对黄金数据进行过采样。
rd	基线方法。通过随机删除生成合成数据,并以与gen相同的比例对黄金数据进行过采样。
rd*	基线方法。与rd 类似,不同之处在于黄金和合成数据的采样相同。

表 1:受监督设置的数据源。

4.2.1 命名实体识别数据集我们在

CoNLL2002/2003 NER 数据（Tjong Kim Sang， 2002；Tjong Kim Sang 和 De Meulder， 2003)上评估我们提出的方法,使用四种语言:英语、德语、荷兰语和西班牙语。此外,我们在泰国和越南的NER数据上评估我们的方法,这些数据是从东南亚国家主要电子商务网站获得的产品标题,并用11个产品属性NER标签进行注释,包括PRODUCT、 BRAND、CONSUMER GROUP、MATERIAL、PAT TERN 、颜色、面料、场合、产地、季节和风格。有关我们实验中使用的泰国和越南 NER 数据的统计数据,请参见附录。

实验设置除了在完整的训练数据上评估我们的方法之外,我们还运行

3条件标记c也在w<t中,因为它是添加到每个句子开头的特殊标记。我们明确地写它来强调条件效应。

4原始论文中提供的基线模型用于评估基于目标的端到端情感分析任务。

[5]对于 NER 和 E2E-TBSA,如果选定的单词出现在实体范围内,则删除整个实体。

Machine Translated by Google

domly 采样 1k、2k、4k、6k 和 8k 句子
为每种语言验证其在低资源设置中的稳健性。我们使用原始开发
和测试数据。语言模型经过训练
在上面的示例句子上,然后用于
按照以下步骤生成合成训练数据
在第3 节中描述。

对于每一批新生成的 1k 个句子
通过训练好的语言模型,我们测量
新出现的 1-gram 标记的百分比
以前的批次。一旦百分比超过
99%,我们将停止数据生成。然后我们对生成的数据进行后期处理（第3.3 节）,并添加
他们将训练数据用于标记模型训练。对于rd和gen,我们对黄金数据进行过采样
在训练中重复 4 次（洗牌）
放。对于随机删除,我们也报告结果
当黄金和合成数据被同等采样时,
用rd*表示。 有关过采样率的超参数选择的其他详细信息可以是
见附录 A.3。继兰普尔等人之后。
（2016）, IOBES 标记方案用于
训练语言模型和序列标记
上述模型。

结果与分析我们在表 2 中报告了 3 次运行的平均结果。我们的方法显示
所有语言的持续性能改进。特别是对于较小的样本集,

我们的方法展示了更显着的性能改进。特别是,建议

与基线方法相比,该方法平均提高了 1.93 和 1.38 点

分别为 1k 和 2k 设置。

Tag-Word vs. Word-Tag如第3.1 节所述,有两种执行句子的方法
线性化:1)在对应的词之前插入标签（Tag-Word）; 2)在对应词之后插入标签（Word-Tag）。保持所有的

其他设置相同,我们发现 Tag-Word 表现优于
NER 任务中的 Word-Tag（如附录所示）
A2）。一个可能的原因是,Tag-Word 更多
与修饰词-名词模式一致,即
在语言建模期间,在训练数据中出现的频率更高。因此,我们使用 Tag-Word
所有NER实验。

6德语在使用时有很大的词外率
静态 fastText 嵌入,与其他语言相比,F1 分数较低。

朗。方法	1k	2k	4k	6k	8k	全部
zh	金	58.06	67.85	74.55	77.16	80.30	83.04
	+rd*	59.42	67.23	74.51	77.39	80.31	83.39
	+rd	58.97	67.81	74.77	77.35	80.59	83.25
	+gen	61.15	70.61	76.82	79.18	81.02	83.74
德6	金	29.71	41.07	49.55	53.30	56.17	61.10
	+rd*	29.89	40.29	49.27	52.33	55.70	60.69
	+rd	30.83	40.36	49.24	53.54	55.60	60.55
	+gen	31.83	40.92	49.79	53.63	56.94	62.44
es	金	58.14	67.42	74.21	77.44	78.90	79.27
	+rd*	58.22	66.98	75.08	77.64	79.11	80.01
	+rd	59.67	68.53	75.21	77.79	79.12	80.26
	+gen	61.76	68.62	76.15	78.20	79.83	80.73
哥兰语	金	37.04	48.61	57.78	61.08	64.59	70.89
	+rd*	35.10	46.45	56.83	60.49	63.09	69.42
	+rd	39.39	48.44	59.38	61.48	64.44	70.36
	+gen	38.87	50.41	59.90	63.19	65.82	72.71
六	金	55.98	62.42	69.01	70.75	72.12	76.14
	+rd*	55.67	63.57	68.47	70.87	72.08	76.43
	+rd	56.24	63.08	68.63	71.15	72.22	76.83
	+gen	60.01	65.43	70.36	72.55	74.11	77.39
th	金	49.88	55.79	61.75	63.10	64.94	67.71
	+rd*	50.46	56.98	62.12	64.19	66.47	67.81
	+rd	50.52	57.42	61.51	64.59	66.07	67.97
	+gen	54.02	59.36	63.94	66.21	68.05	69.86

表 2:命名实体识别微 F1。

4.2.2 词性标注

数据集我们使用来自 Universal De 的 POS 数据
pendencies treebanks7用于评估此任务。
我们评估五种语言,包括英语,
西班牙语、捷克语、罗马尼亚语和日语。每个
语言在通用依赖树库中有多个语料库,所以我们合并语料库
为三种语言构建一个数据集:英语,
西班牙语和捷克语。对于英语,我们合并 GUM,
PartTUT、PUD 和线路。对于西班牙语,我们合并
AnCora 和 GSD。对于捷克语,我们合并了 PDT、Fic
Tree、CLTT 和 CAC。我们还评估了我们的
日语 (GSD) 和罗马尼亚语 (RRT) 模型,
这些语言要么由少得多的人口使用,要么来自不同的语系。

设置和结果我们遵循与 NER 任务类似的实验设置。相同的语言

模型和 BiLSTM-CRF 序列标注模型
分别用于合成数据生成和 POS 标记。与 NER 不同,Word-Tag
在 POS 任务中表现出稍好的性能（参见附录 A.2）。我们在表 3 中展示了 3 次运行的平均 Word Tag 结果。我们的方法展示了所有性能的一致改进

语言。与NER类似,我们的方法demon

[7]https://universaldependencies.org/

Machine Translated by Google

朗。方法 1k	2k	4k	6k	8k 满
zh	金 79.18 82.17 85.83 88.62 90.21 93.00			
	+rd* 79.28 82.42 85.82 88.55 90.07 92.89			
	+rd 79.38 82.50 86.08 88.80 90.15 92.96			
	+gen 79.76 82.90 86.31 88.99 90.56 93.29			
es	金 88.28 90.79 92.82 93.80 94.43 96.40			
	+rd* 88.25 90.94 92.84 93.76 94.48 96.41			
	+rd 88.17 90.78 92.79 93.67 94.28 96.45			
	+gen 88.77 91.04 93.12 93.93 94.64 96.45			
cz	金 80.10 84.46 88.88 90.67 92.03 97.52			
	+rd* 79.83 84.29 88.64 90.43 91.95 97.57			
	+rd 80.11 84.50 88.99 90.66 91.86 97.60			
	+gen 80.65 85.17 89.58 91.22 92.49 97.63			
ro8	金 86.69 89.57 92.73 93.84 94.54 94.54			
	+rd* 86.42 89.58 92.50 93.89 94.64 94.64			
	+rd 86.62 89.46 92.55 93.84 94.73 94.73			
	+gen 87.29 90.66 93.44 94.61 95.17 95.17			
ja9	金 90.19 91.44 93.59 94.41 +rd* 90.00 91.41		-	95.08
	93.66 94.62 89.53 91.76 93.62 94.59		-	94.93
	+rd		-	95.18
	+gen 91.00 92.51 94.12 95.21		-	95.45

表 3:POS 标记精度。

战略更显着的性能改进
对于 POS 标记上的较小样本集。特别是,所提出的方法平均达到0.56 ,
相比于 0.60 和 0.46 点的改进
1k、2k 和 4k 设置中的基线方法,
分别。

4.2.3 基于目标的情感分析

数据集我们使用Li 等人处理的笔记本电脑和餐厅评论数据集。(2019a)为
对 E2E-TBSA 的评估,最初是从 SemEval ABSA 挑战中获得的（Pontiki
等人， 2014 年、 2015 年、 2016 年）。我们合并这两个
查看数据集,随机保留10%
训练数据作为开发集,并从剩余的训练数据中随机抽取较小的数据集
对于低资源设置。原始测试集是
合并为我们的测试集。

设置和结果我们遵循与NER 和 POS 任务类似的实验设置,除了
Li发布的同一个序列标注模型
等。 （2019a)用于评估。这里 Tag Word 显示了更好的结果（请参阅附录 A.2）,
似乎是因为统一的标签（例如 B-POS,
和 B-NEG) 与名词修饰语相似,而 Tag Word 与修饰语-名词更一致
图案。我们展示了平均标签词结果
表 4 中的 3 次运行。我们的方法演示了

8UD-RRT 全套训练有 8k 罗马尼亚语句子。
9UD-GSD 完整的训练集有 7k 句日语。

4k及以上的性能提升。与NER和 POS 数据集相比,
E2E TBSA 数据集的标签要少得多,因此结果

不太稳定。

方法 2k	4k 全部（6k）
金	56.31 60.43 63.18
+rd*	57.92 61.75 63.66
+gen	57.07 62.66 65.86

表 4:E2E-TBSA 微型 F1。

4.3 半监督实验

在本节中,我们评估我们的有效性
两种半监督设置中的方法:1)仅
未标记的数据可用； 2)两个未标记的数据
和知识库可用。见表5
对于我们的半成品中使用的方法的符号
监督实验。

方法说明	
金子	监督方法。仅使用黄金数据。
重量	基线方法。用 a 注释未标记的数据 弱标注器（即在黄金上训练的标注模型 数据）。
genud	我们的方法。使用 LM 生成合成数据,其中 LM 接受黄金数据和未标记数据的训练。
KB	基线方法。注释未标记的数据 知识库。
genkb	我们的方法。使用 LM 生成合成数据,其中 LM 接受过黄金数据和知识库以及标注数据的培训。

表 5:半监督设置的数据源。

4.3.1 仅使用未标记的数据

数据集我们使用 CoNLL2003 英文 NER 数据
（Tjong Kim Sang 和 De Meulder， 2003 年)进行评估。
除了黄金 NER 训练数据,我们
利用未标记的数据进行半监督训练。
斯坦福 CoreNLP 分词器（Manning 等人，
2014)用于标记维基百科的句子。

实验设置与上述实验类似,我们使用 1k、2k、4k、6k 和 8k 句子
从 NER 黄金数据中随机抽样,以及
完整的数据集来评估我们的方法。为了公平
相比之下,我们只使用从 Wikipedia dump 中随机抽取的同一组 10k句
我们的方法和基线方法。让Dgold和
Dunlabeled是采样的黄金 NER 数据和
维基百科数据,分别。
在我们的方法中,将 Dgold和Dunlabeled连接起来以训练语言模型,遵循以下步骤

Machine Translated by Google

方法	1k	2k	4k	6k	8k	全部
金子	58.06	67.85	74.55	77.16	80.30	83.04
+重量	65.12	72.43	77.90	79.41	81.36	84.00
+genud	66.19	73.00	78.08	79.75	81.98	84.33
+kb	67.36	72.86	77.15	79.33	81.91	83.69
+genkb	66.67	73.54	78.32	79.98	81.93	84.03

表 6:半监督 NER F1。

在第3.4 节中描述。然后我们使用语言模型生成合成数据,将20k个随机采样的句子与Dgold结合起来训练 NER 模型。我们使用genud来表示这种数据生成方法。使用弱标记器注释Dunlabeled的方法用作我们的基线,用wt 表示。本实验中较弱的标注器是在Dgold 上训练的 NER 模型。我们使用相同的NER 模型 (BiLSTM-CRF) 和超参数来评估我们的方法和基线方法。在训练语言模型时,我们同样从Dgold和Dunlabeled中采样句子。在训练 NER 模型时,我们通过重复Dgold 4 次对黄金数据进行过采样,以创建一个混洗训练文件。

结果和分析我们在表6中报告了wt和genud的 F1（3 次运行的平均值）。我们的方法在所有设置上都优于基线方法wt 。

此外,通过使用大量未标记的数据进一步探索我们模型的能力将是一个有希望的方向。在基线方法wt中使用大量未标记的数据不是很方便,因为这将直接增加增强数据的数量。结果,在序列标记模型收敛之前,可能无法使用一些增强数据。然而,我们的方法genud可以方便地利用大量未标记的数据来训练语言模型,从而直接提高数据增强质量。当未标记的数据量很大时,我们可以用未标记的数据预训练语言模型,然后用标记的数据对其进行微调。

4.3.2 使用未标记的数据和知识库

数据集除了第4.3.1 节中使用的黄金训练数据和未标记的句子外,我们还尝试利用知识库在本实验中进一步提高性能。我们通过提取实体（区分大小写并至少出现两次)和相关信息来构建知识库从完整的黄金训练数据中响应标签。
此外,我们通过包含从 geonames10 中提取的城市和国家,将更多 LOC 实体添加到该知识库中。

实验设置我们以与第4.3.1节相同的方式随机采样黄金NER 数据和维基百科数据,其中采样的句子分别用Dgold和Dunlabeled表示。

我们的知识库用于通过在每个句子中查找最长的前向匹配（从左到右)来注释Dunlabeled 。我们用kb表示这个注释方法,用Dkb表示注释数据。

在我们的方法中,按照第3.4节中描述的步骤,连接Dgold和Dkb以训练语言模型。然后我们使用语言模型生成合成数据,将 20k个随机采样的句子与Dgold结合起来训练 NER 模型。我们使用genkb来表示这种数据生成方法,并将其与基线方法kb 进行比较。与上述实验类似,我们在训练语言和 NER 模型时对Dgold进行过采样。

结果与分析我们在表 6 中展示了kb和genkb的 F1 （3 次运行的平均值）。基线方法kb在Dgold规模较小时表现出非常强的性能,因为我们使用国家和城市的大型知识库进行注释,并且与其他类型的实体相比,位置名称不那么模棱两可。然而,当Dgold的大小大于 2k时,我们的方法仍然优于kb ,这表明当可用的黄金数据量稍大时,我们的方法对Dkb中的噪声更加鲁棒。

5 仔细研究合成数据

在本节中,我们将更详细地探讨为什么我们的方法生成的合成数据可以帮助提高序列标记性能。通过仔细查看生成的数据,我们有几个有趣的发现。

更多的多样性生成的合成数据引入了更多的多样性,以帮助减少过度拟合。
如图4 所示的示例,黄金训练数据中的名称“San drine”总是与不同句子中的“Testud”配对。然而,在生成的数据中,我们可以看到已经生成了新的名称,例如“Sandrine Nixon”、“Sandrine Okuda”和“Sandrine Neumann”。同时,

10https://datahub.io/core/world-cities

Machine Translated by Google

Gold Training Data

1. ... [B-PER Sandrine] [E-PER Testud] ([S-LOC France]) beat ...
2. ... [B-PER Sandrine] [E-PER Testud] ([S-LOC France]) ...
3. ... beat [B-PER Sandrine] [E-PER Testud] ([S-LOC France]) ...
4. ... [B-PER Sandrine] [E-PER Testud] ([S-LOC France]) beat ...

Generated Data

1. ... [B-PER Sandrine] [E-PER Testud] ([S-LOC Sweden]) ...
2. ... [B-PER Sandrine] [E-PER Nixon] fled to ([S-LOC Egypt]) ...
3. ... [B-PER Sandrine] [E-PER Okuda] ([S-LOC Australia]) ...
4. ... [B-PER Sandrine] [E-PER Neuumann] ([S-LOC France]) beat ...

图 4:生成数据多样性的说明。
黄金训练数据中的名称“Sandrine”总是与句子中的“Testud”配对。

句子中的位置已被替换为“瑞典”、“埃及”和“澳大利亚”等新国家。有了这些合成数据,该模型可以专注于学习实体出现的上下文模式,而不是简单地记住“Sandrine Testud”作为人名和“France”作为位置。

为了定量测量我们的方法带来的多样性及其影响,我们对受监督的英语 NER 生成数据中的上下文实体 (CEs) 进行了一些统计分析。 CE 指的是实体及其 1-gram 上下文的组合。例如,在句子“[B-ORG European] [E-ORG Commission] said ...”中,实体是“European Commission”,其 CE 是“The European Commission said”。如图5 所示,我们计算了黄金训练数据中唯一 CE 的数量、生成数据中新的唯一 CE的数量以及这两个数字的比率。我们还在这里绘制了我们的方法（即黄金+gen)相对于仅使用黄金数据的 F1 改进,如表2 所示。我们可以看到我们的方法生成了大量新的 CE,这种多样性增强了训练好的模型。当比率越高时,F1 的改进就越显着,这也表明我们的方法确实通过生成丰富的新实体和上下文来帮助缓解资源不足的问题。关于唯一实体（无上下文)的统计,请参阅附录 A.5,其中显示了相同的结论。

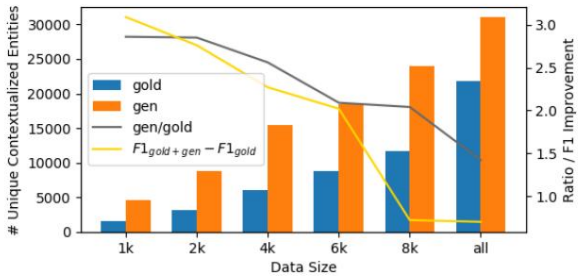

图 5:独特上下文实体的统计数据。

何时有效利用未标记数据

未标记的数据可用,我们的方法可以灵活地利用它们进行半监督训练。我们在合成数据中发现了许多有趣的例子,表明我们的方法可以有效地使用未标记的数据来提取有用的信息。在

由我们的方法生成的示例“... [B ORG Bank] [I-ORG of] [E-ORG Alabama] ...”,“Alabama”一词从未出现在黄金NER 训练数据中。然而,我们的语言模型了解到“Alabama”（来自未标记的数据)与出现在黄金训练数据和未标记数据中的其他位置词非常相似。所以在生成合成数据时,语言模型可以在类似的上下文中使用这个词,甚至可以创建新的实体（这个例子中的“阿拉巴马银行”从未出现在黄金或未标记的数据中）。

六,结论

在本文中,我们展示了语言模型可用于为序列标记任务生成高质量的合成数据。生成的数据引入了更多的多样性以减少过度拟合,因为它们是从头开始生成的,而不是修改黄金训练数据。我们提出的方法在各种标记任务上展示了有希望的性能改进,特别是在低资源设置中。此外,实验表明我们的方法还可以有效地利用未标记的数据和知识库进行半监督训练。

致谢

这项研究得到了南洋理工大学阿里巴巴南大新加坡联合研究院的部分支持。刘琳琳感谢南洋理工大学交叉学科研究生院的支持。

参考

Alan Akbik、Tanja Bergmann、Duncan Blythe、Kashif Rasul、Stefan Schweter 和 Roland Vollgraf。 2019 年。Flair:一个易于使用的最先进的 nlp 框架。在美国商业协会北美分会 2019 年会议记录中

Machine Translated by Google

推定语言学（演示），第 54 页–
59.

Alan Akbik、Duncan Blythe 和 Roland Vollgraf。
2018. 序列的上下文字符串嵌入
标签。在第 27 届国际会议上
计算语言学会议，页数
1638–1649。

Ateret Anaby-Tavor, Boaz Carmeli, Esther Goldbraich,
阿米尔·坎特、乔治·库尔、塞格夫·什洛莫夫、纳马
Tepper 和 Naama Zwerdling。 2020.没有
足够的数据?深度学习救命!在第三十三届 AAAI 人工智能会议
上。

M Saiful Bari、Tasnim Mohiuddin 和 Shafiq Joty。
2020. Multimix:跨语言 nlp 的强大数据增强框架工作。

Bernd Bohnet, Ryan McDonald, Gonc¸alo Simoes, ~
丹尼尔安道尔、艾米莉皮特勒和约书亚梅内斯。
2018. 使用元数据进行形态句法标记
对上下文敏感的令牌编码进行建模。在
计算语言学协会第 56 届年会论文集（第 1 卷：

长论文），第 2642-2652 页。

Piotr Bojanowski、Edouard Grave、Armand Joulin 和
托马斯·米科洛夫。 2017. 丰富词向量
子词信息。计算语言学协会汇刊，5:135-146。

Peng Chen、Zhongqian Sun、Lidong Bing、Wei
杨。 2017. 用于方面情感分析的内存上的循环注意网络。在诉
讼中
EMNLP，第 463-472 页。

李东、乔纳森·马林森、西瓦·雷迪和米雷拉
拉帕塔。 2017.学习解释问题
回答。在 2017 年会议记录中
自然语言处理中的经验方法，第 875-886 页，丹麦哥本哈根。计
算语言学协会。

安东尼奥·德因诺森特、法比奥·玛丽亚·卡鲁奇、米尔科
科洛西和芭芭拉·卡普托。 2017. 通过数据增强连接计算机和
机器人视觉:对象识别案例研究。在计算机视觉系统国际会议
上，

第 384-393 页。施普林格。

Marzieh Fadaee、Arianna Bisazza 和 Christof Monz。
2017. 低资源神经网络的数据增强
机器翻译。在计算协会第 55 届年会的会议记录中

语言学（第 2 卷:短篇论文），第 567 页–
573.

侯赛因·法齐、霍斯特·萨穆洛维茨、迪帕克·图拉加、
和帕斯卡·弗罗萨德。 2016. 图像分类的自适应数据增强。
2016年IEEE国际图像处理会议（ICIP），

第 3688-3692 页。易。

本杰明·海因策林和迈克尔·斯特鲁布。 2019. 带有上下文和非上
下文的序列标记
子词表示:多语言评估。
在计算语言学协会第 57 届年会的会议记录中，第 273 页–

291.

Nitish Shirish Keskar, Bryan McCann, Lav R Varshney,
熊才明和理查德·索彻。 2019. 控制:A
用于控制标签生成的条件转换器语言模型。 arXiv 预印本
arXiv:1909.05858。

Diederik P Kingma 和 Jimmy Ba。 2014.亚当:一个
随机优化方法。 arXiv 预印本
arXiv:1412.6980。

汤姆·柯、维杰亚蒂亚·佩丁蒂、丹尼尔·波维、
Michael L Seltzer 和 Sanjeev Khudanpur。
2017. 混响数据增强研究
用于鲁棒语音识别的语音。 2017年IEEE
声学、演讲和国际会议
信号处理 (ICASSP)，第 5220-5224 页。
IEEE。

小林宗介。 2018. 上下文增强：
通过具有范式关系的单词进行数据扩充。在 2018 年会议记录
中
北美分会
计算语言学:人类语言技术，第 2 卷（短论文），第 452-457
页。

卡纳赛克鲁恩克莱。 2019. 更好地利用潜
文本建模中的变量。在诉讼中
计算语言学协会第 57 届年会，第 5527-5532 页。

Varun Kumar、Ashutosh Choudhary 和 Eunah Cho。
2020. 使用预训练的变压器模型进行数据增强。 arXiv 预印
本 arXiv:2003.02245。

Guillaume Lample、Miguel Ballesteros、Sandeep Sub
ramanian、Kazuya Kawakami 和 Chris Dyer。 2016 年。
用于命名实体识别的神经架构。
arXiv 预印本 arXiv:1603.01360。

李静、孙爱欣、韩江雷、李晨亮。
2020. 命名实体深度学习调查
认出。 IEEE Transactions on Knowledge and
数据工程。

李鑫、李冬兵、李皮吉和韦林。 2019a。一种
意见目标抽取与目标统一模型
情绪预测。在 AAAI 会议记录中
人工智能会议，第 33 卷，
第 6714-6721 页。

李鑫、李冬兵、李皮吉、伟林、志某
杨。 2018.具有关注历史和选择性转换的方面术语提取。在诉
讼中
第 27 届国际人工智能联合会议 (IJCAI)，第 4194 页 –

4200。

新李、李东兵、张文轩和伟林。
2019b。利用 BERT 进行基于端到端方面的情感分析。在诉讼中

Machine Translated by Google

分析。在第九届国际会议记录中

Machine Translated by Google

Erik F. Tjong Kim Sang 和 Fien De Meulder。 2003. CoNLL-2003 共享任务简介：与语言无关的命名实体识别。在 2003 年 HLT-NAACL 第七届自然语言学习会议论文集，页数 142–147。

王定全和杰森·艾斯纳。 2016. 银河依赖关系树库：通过合成新语言来获取更多数据。计算语言学协会汇刊，4:491-505。

王向、王凯、连世国。 2019. 一个人脸数据增强调查。 arXiv 预印本 arXiv:1904.11685。

杰森·魏和邹凯。 2019. Eda：用于提高文本性能的简单数据增强技术分类任务。在 2019 年自然语言经验方法会议论文集中处理和第 9 届自然语言处理国际联合会议 (EMNLP IJCNLP)，第 6383-6389 页。

Jason Weston、Antoine Bordes、Sumit Chopra、Alexan der M Rush、Bart van Merrienboer、Armand Joulin 和 Tomas Mikolov。 2015. 迈向人工智能完备问答：一组必备的玩具任务。 arXiv 预印本 arXiv:1502.05698。

David Yarowsky、Grace Ngai 和 Richard Wicen 托夫斯基。 2001. 诱导多语言文本分析通过跨对齐语料库的稳健投影工具。技术报告，JOHNS HOPKINS UNIV BALTI MORE 计算机科学系。

安永道弘、葛西贞吾、德拉戈米尔拉德夫。 2018. 强大的多语言词性通过对抗训练进行标记。在诉讼中计算语言学协会北美分会 2018 年会议：人类语言技术，第 1 卷（长论文），第 976-986 页。

Adams Wei Yu, David Dohan, Quoc Le, Thang Luong, 赵睿，陈凯。 2018.快速准确结合自注意力的阅读理解和卷积。在国际会议上学习表示。

附录

A.1 泰国和越南NER统计数据

我们用泰语和表7中的越南 NER 数据。

朗。	训练	开发	测试
六	18,922	500	500
th	11,272	499	490

表 7：TH 和 VI NER 数据中的句子数。

A.2 Tag-Word 与 Word-Tag 的实验

我们进行实验来比较Tag-Word 和 Word-Tag 的标记性能任务。所有其他设置与主要论文中提出的相应实验相同。结果报告在表8至10中。 Tag-Word 为 NER 提供更好的平均性能，并且 E2E-TBSA，而 Word-Tag 略胜一筹 Tag-Word 用于 POS 标记。

朗。	方法	1k	2k	4k	6k	8k	全平均
zh	标签字	59.39	69.48	75.68	78.65	80.19	83.70	74.52
	字标签	58.97	67.32	75.45	78.06	80.43	83.58	73.97

表 8：ConLL NER F1：Tag-Word vs. Word-Tag。

朗。	方法	1k	2k	4k	8k	15k	平均
zh	标签字	79.06	82.43	85.93	90.38	92.75	86.11
	字标签	79.18	82.64	86.13	90.33	92.68	86.19

表 9：Universal Dependencies POS 准确度：Tag Word vs. Word Tag。

朗。	方法	2k	4k	满（6k)	平均
zh	标签字	54.22	61.72	62.88	59.61
	字标签	55.58	59.42	61.65	58.88

表 10：E2E-TBSA micro F1：Tag-Word vs. Word Tag。

A.3 过采样率实验

我们进行实验以比较NER 任务的不同过采样率。报告结果在表11中。符号 gold×N表示我们通过在 shuffled 中重复N 次来对gold 进行过度采样静态训练数据。

A.4 部分的半监督实验语音标记

数据集我们使用来自 Uni versal Dependencies treebanks 的英语 POS 数据来评估这个任务。我们将 GUM、PartTUT、PUD 和用于构建英语数据集的行语料库。类似于 NER 的半监督实验，我们还利用未标记的维基百科句子训练。

实验设置我们使用 1k、2k、4k、6k 和从英语中随机抽取的 8k 个句子 POS黄金数据以及要评估的完整数据集我们的方法。我们遵循与NER 的半监督实验相同的实验设置

Machine Translated by Google

朗。方法 1k	2k	平均 4k
zh	金×1 59.74 69.14 76.48 68.45	
	金×2 60.92 69.79 76.57 69.09	
	金×3 61.13 70.42 74.92 67.24	
	金×4 61.15 70.61 76.82 69.53	
	金×5 61.43 70.38 76.43 69.41	

表 11:ConLL NER F1:不同的比较
过采样率。

生成合成数据,训练序列标记
对 POS 测试数据进行建模和评估。

结果和分析我们报告重量的准确性
和表12中的genud （3 次运行的平均值） 。我们的
方法优于基线方法wt时
金句数少于8k。
当金句数超过
8k,我们方法的性能是可比的
与重量。

方法 1k	2k	4k	6k	8k	全部
金子	79.18 82.17 85.83 88.62 90.21 93.00				
+重量	81.11 84.00 86.91 89.64 90.88 93.20				
+genud	82.11 84.93 87.52 89.98 90.84 93.12				

表 12:半监督 POS 准确度。

A.5 综合数据多样性:独特
实体

定量测量引入的多样性
通过我们在有监督的英语 NER 任务中的方法，
我们计算唯一实体的数量（没有
上下文)在黄金和生成的数据中。结果是
如图6 所示。

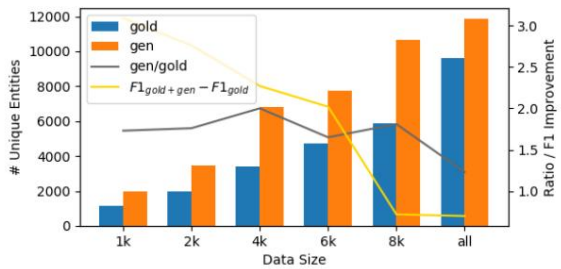

图 6:唯一实体的统计信息（无上下文）

A.6 平均运行时间

表13是平均运行时间的说明
我们的英语 NER、POS 和 E2E-TBSA 模型
任务和 RNNLM。

任务	1k 2k	4k	6k	8k	全部
NER	26.5 70.5 124.4 167.9 216.3 393.2				
POS	83.6 112.3 231.1 257.7 277.2 298.0				
E2E-TBSA - RNNLM	89.3 150.8 269.2			-	-
0.7	1.1	2.0	2.7	3.3	3.9

表 13:平均运行时间（分钟）。

A.7 计算基础设施

我们在 NVIDIA V100 上进行实验
显卡。